

Nama : Pradipta Thomas Bhaskara

NIM : 251012050092



Berikut adalah tahapan penerapan NLP langkah-demi-langkah (step-by-step) di dalam kode:

1. Case Folding & Cleansing (Pembersihan Teks)

Langkah awal ini bertujuan untuk menyamakan format teks dan menghapus karakter yang tidak bermakna (noise) agar pencocokan nantinya lebih konsisten.

- Case Folding: Mengubah seluruh huruf menjadi huruf kecil (lowercase). Dengan begitu, kata "Monstera", "MONSTERA", dan "monstera" akan dianggap sama oleh sistem.

```
text = text.lower() # Baris 60 & 255
```

- Cleansing: Menghapus angka (`\d+`) dan tanda baca (`string.punctuation`) menggunakan Regular Expression (`re`) dan pemetaan karakter.

```
text = re.sub(r'\d+', '', text) # Menghapus angka (Baris 62 & 258)
```

```
text = text.translate(str.maketrans("", "", string.punctuation)) # Menghapus tanda baca (Baris 64 & 261)
```

2. Tokenization (Tokenisasi)

Proses memotong satu kalimat utuh menjadi potongan kata-kata yang disebut token. Pada kode ini, tokenisasi dilakukan menggunakan fungsi dari library `nlTK` (Natural Language Toolkit).

- Kode:

```
tokens = word_tokenize(text) # Baris 66 & 264
```

- Contoh: Kalimat "cara merawat monstera" setelah ditokenisasi menjadi list kata: `['cara', 'merawat', 'monstera']`.

3. Stopword Removal (Penyaringan Kata Kunci)

Proses membuang kata-olah (stopword)—yaitu kata-kata umum yang sering muncul tetapi tidak memiliki makna penting dalam menentukan maksud/konteks kalimat (seperti "yang", "untuk", "di", "dan").

- Kode:

```
tokens = [w for w in tokens if w not in stop_words] # Baris 68 & 267
```

- Aplikasi mengambil daftar stopwords Bahasa Indonesia dari NLTK (atau daftar cadangan statis di baris 49-55 jika koneksi unduhan gagal).
- Contoh: Kalimat "bagaimana cara merawat monstera", setelah tokenisasi dan stopwords removal, kata tanya seperti "bagaimana" akan dibuang, menyisakan token penting: ['cara', 'merawat', 'monstera'] .

4. Stemming Sastrawi (Transformasi Kata Dasar)

Mengubah kata-kata berimbuhan menjadi kata dasar (lemma) menggunakan algoritma stemming khusus Bahasa Indonesia dari library PySastrawi. Ini sangat krusial karena Bahasa Indonesia memiliki banyak imbuhan (prefix, suffix, confix).

- Kode:

```
tokens = [stemmer.stem(w) for w in tokens] # Baris 70 & 270
```

- Contoh: Kata "merawat" memiliki kata dasar "rawat". Melalui proses ini, kata "merawat", "perawatan", atau "dirawat" semuanya akan dirubah menjadi satu bentuk dasar: "rawat". Hal ini meminimalisir variasi kata dan meningkatkan akurasi pencarian.

5. TF-IDF Vectorization (Pembobotan Kata)

Setelah query bersih dan menjadi kata dasar (misal: "cara rawat monstera"), teks tersebut diubah menjadi bentuk angka (vektor numerik) agar bisa diproses secara matematis. Metode yang digunakan adalah TF-IDF (Term Frequency - Inverse Document Frequency).

- TF (Term Frequency): Seberapa sering suatu kata muncul dalam satu pola.
- IDF (Inverse Document Frequency): Seberapa unik atau penting kata tersebut di seluruh pola yang ada di dataset. Kata yang terlalu umum di semua dokumen (misal: "tanaman") akan diberi bobot kecil, sedangkan kata yang spesifik (misal: "monstera") diberi bobot besar.
- Kode:

```
vectorizer = TfidfVectorizer(token_pattern=r"(?u)\b\w+\b") # Baris 91
```

```
X = vectorizer.fit_transform(corpus) # Baris 92 (Melatih model TF-IDF dari dataset pola)
```

```
query_vector = vectorizer.transform([clean_query]) # Baris 276 (Mengubah input user menjadi vektor)
```

6. Cosine Similarity Matching (Pengukuran Kemiripan)

Tahap akhir untuk menentukan respon terbaik. Sistem akan mengukur sudut kemiripan antara vektor query pengguna dengan semua vektor pola pertanyaan yang ada di dataset (tanaman_hias.json).

- Metode: Cosine Similarity menghitung nilai kosinus sudut antara dua vektor di ruang multi-dimensi. Nilainya berkisar antara 0 (tidak ada kemiripan sama sekali) hingga 1 (identik/sangat mirip).
- Kode:

```
similarities = cosine_similarity(query_vector, X)[0] # Baris 277
```

- Threshold (Ambang Batas): Ditentukan batas minimal skor kemiripan sebesar 0.15 (Baris 295-296). Jika skor tertinggi di bawah 0.15 , bot akan mengeluarkan respon default (tidak paham). Jika di atas 0.15 , bot akan memilih respon acak dari daftar respon yang terikat dengan pola/tag terbaik tersebut (Baris 297-302).

Summary Workflow :

Kalimat Input →

Case Folding & Cleansing (Ubah huruf kecil & hapus tanda baca/angka) →

Tokenisasi (Pecah jadi kata) →

Stopword Removal (Buang kata tidak penting) →

Stemming (Ubah ke kata dasar via Sastrawi) →

TF-IDF Vectorization (Ubah jadi angka/vektor berbobot) →

Cosine Similarity (Hitung kemiripan sudut dengan database) →

Thresholding (Cek apakah kemiripannya ≥ 0.15) →

Output Jawaban/Respon.